

- (۱) برای هر یک از گزاره‌های زیر مشخص کنید آیا مغالطه آماری وجود دارد یا خیر. پاسخ خود را به طور کامل توضیح داده و در صورت وجود مغالطه آماری نحوه تصحیح تحلیل یا جمع‌آوری داده را شرح دهید. (۱۸ نمره)
- الف) بر اساس یک پژوهش جدید که بر روی دانشجویان دانشگاه تهران انجام شده، میانگین ضریب هوشی شرکت‌کنندگان در این پژوهش ۱۱۵ بوده است. محققان این پژوهش نتیجه‌گیری کرده‌اند که میانگین ضریب هوشی ایرانیان بالاتر از میانگین جهانی (که حدود ۱۰۰ است) قرار دارد و این نشان‌دهنده هوش برتر مردم ایران است.
- ب) در یک پژوهش پزشکی برای بررسی اثربخشی یک داروی جدید، $p\text{-value}$ برابر با ۰.۰۳ به دست آمده است. محقق نتیجه‌گیری می‌کند که ۹۷ درصد احتمال دارد که این دارو مؤثر باشد.
- پ) یک شرکت توسعه‌دهنده نرم‌افزار مدیریت پروژه برای شناسایی نقاط قوت محصول خود، یک نظرسنجی برای کاربران فعلی و فعال خود ارسال می‌کند. نتایج نظرسنجی نشان می‌دهد که ۹۵ درصد از پاسخ‌دهندگان از ویژگی‌های اصلی نرم‌افزار بسیار راضی هستند. مدیر محصول با استناد به این داده‌ها نتیجه‌گیری می‌کند که نیازی به تغییرات اساسی در استراتژی توسعه وجود ندارد، زیرا اکثریت قاطع کاربران از آن رضایت کامل دارند.
- (۲) یک شرکت فعال در حوزه شبکه‌های اجتماعی قصد دارد قابلیت جدیدی به پلتفرم خود اضافه کند که به صورت خودکار یک زیرنویس کوتاه (مثلاً: یک سگ در حال دویدن در ساحل) برای ویدئوهای کوتاه بارگذاری شده توسط کاربران تولید کند. از شما خواسته شده است تا یک مدل یادگیری عمیق برای این منظور طراحی کنید. (۱۵ نمره)
- الف) چرا استفاده از یک شبکه پیچشی (CNN) به تنهایی برای این کار کافی نیست؟ به طور مشخص توضیح دهید که CNN چه بخشی از اطلاعات موجود در ویدئو را می‌تواند استخراج کند و چه بخشی را نادیده می‌گیرد.
- ب) چرا استفاده از یک شبکه بازگشتی (RNN) به تنهایی برای این کار کافی نیست؟ توضیح دهید که RNN برای پردازش چه نوع داده‌ای طراحی شده و چرا نمی‌تواند به طور مستقیم ورودی خام ویدئو را به خوبی پردازش کند.
- پ) توضیح دهید که چگونه می‌توان از نقاط قوت هر یک از معماری‌های CNN و RNN برای حل این مسئله به صورت ترکیبی استفاده کرد. نقش هر شبکه را در این سیستم ترکیبی به وضوح مشخص کنید.
- (۳) یک شرکت بزرگ خرده‌فروشی آنلاین قصد دارد مشتریان خود را به منظور بازاریابی هدفمند، به بخش‌های معنادار تقسیم کند. داده‌های موجود برای هر مشتری شامل ده‌ها ویژگی مختلف است، از جمله اطلاعات فردی (سن، موقعیت جغرافیایی و ...)، تاریخچه خرید (تعداد کل خریدها، میانگین مبلغ هر خرید، ...)، و رفتار در وبسایت: بردار بسیار بزرگی که نشان می‌دهد مشتری از کدام یک از هزار دسته‌بندی مختلف محصولات (مانند لوازم الکترونیکی، کتاب، پوشاک ورزشی و ...) بازدید کرده یا خرید انجام داده است. هدف، شناسایی گروه‌های طبیعی از مشتریان با رفتارهای مشابه است (مثلاً خریداران وفادار با ارزش بالا یا خریداران تخفیف‌محور و کم‌تکرار). (۱۶ نمره)
- الف) توضیح دهید که چرا وجود بردار رفتار در وبسایت با بعد هزار، می‌تواند مستقیماً بر عملکرد یک الگوریتم خوشه‌بندی مبتنی بر فاصله مانند $k\text{-means}$ تأثیر منفی بگذارد. حداقل دو دلیل ذکر کنید.
- ب) آیا اجرای یک الگوریتم کاهش ابعاد قبل از اجرای الگوریتم خوشه‌بندی، یک استراتژی هوشمندانه در این سناریو محسوب می‌شود؟ چرا؟

پ) پس از اینکه الگوریتم، هر مشتری را به یک خوشه تخصیص داد، چگونه می‌توان به هر خوشه یک برچسب معنادار اختصاص داد؟

ت) فرض کنید مجموعه داده شما داده‌های پرت زیادی دارد. آیا استفاده از **k-means** همچنان مناسب است یا باید روش جایگزینی را انتخاب کرد؟ چرا؟

۴) درست یا غلط؟ (با توجیه مختصر) (۹ پرسش) (۲۷ نمره)

الف) برای اینکه از **overfitting** یک مدل پیش‌بینی پیش‌گیری کنیم، بهتر است داده‌های آموزش بیشتری جمع‌آوری کنیم.

ب) در زمان آموزش و به منظور تخمین دقت یک دسته‌بند، بهترین راه استفاده از داده آزمون می‌باشد.

پ) بین دقت و تفسیرپذیری یک مدل، اغلب یک **tradeoff** وجود دارد.

ت) مدل چت‌جی‌پی‌تی تنها از طریق آموزش بر روی داده‌های خام متنی آموزش دیده شده است.

ث) اگر مدلی بین دو متغیر X و Y به صورت $Y = \Theta_0 + \Theta_1 X^2$ تعریف شود، دیگر نمی‌توان از روشهای **simple linear regression** برای تخمین پارامترهای Θ استفاده کرد.

ج) درخت تصمیم یا جنگل تصادفی قابلیت تفسیرپذیری بهتری نسبت به شبکه‌های عصبی به ما می‌دهند.

چ) تابع **softmax** در یک **logistic regression** نمی‌تواند برای دسته‌بندی دودویی (باینری) استفاده شود.

ح) الگوریتم گرادیان کاهشی یک الگوریتم تکراری ست که برای یک مساله همیشه به یک جواب می‌رسد.

خ) استفاده از **svm** درحالی که **outlier** داریم، امکان‌پذیر نیست.

۵) پرسش‌هایی با پاسخ کوتاه (۸ پرسش) (۲۴ نمره)

الف) جدولی داریم از جمعیت شهرهای ایران که مشخصات شهر شامل موارد (name, geolocation, province, population) هست. برای حداکثر و متوسط جمعیت در هر استان از چه **SQL query** استفاده کنیم؟

ب) منظور از **composition function** در شبکه پردازش زبان چیست؟

پ) چرا در الگوریتم گرادیان کاهشی از **mini-batch** استفاده می‌شود؟

ت) چطور از مصورسازی می‌توان برای تشخیص دقت یک مدل **fit** شده بر روی یک دیتا استفاده کرد؟

ث) چرا تخمین مقدار یک داده از روی داده‌های دیگر همیشه خوب نیست؟ (می‌توانید با یک مثال توضیح دهید)

ث) نمودار **precision / recall** چطور بدست می‌آید؟

ج) چرا با وجود اینکه یک ترکیب از پارامترها در یک مدل خطی مقدار هزینه‌ی کمتری دارد، ما ترکیب دیگری را ممکن است ترجیح دهیم؟

چ) فرض کنید که استانداردسازی شامل نرمال‌سازی داده‌ها را انجام نداده‌ایم. استفاده از چه الگوریتمی برای پیش‌بینی را پیشنهاد می‌کنید و چرا؟