

دقت کنید که برای توضیح بخشی از پاسخ‌ها به صورت شفاهی دعوت خواهید شد.

بخش اول: سوالات چهارگزینه‌ای (۲.۲۵ نمره) (با توضیح مختصر)

۱. کدام مورد بیشترین تهدید را برای اعتبار نتایج آماری ایجاد می‌نماید؟ (۰.۲۵ نمره)
- الف) رسم نمودار نامناسب
ب) تعداد محدودی داده‌ی گم‌شده^۱
ج) نمونه‌ی غیرنماینده از جامعه
د) مرتب‌نبودن داده‌ها
۲. کدام تغییر، بیشترین احتمال را دارد که مقدار میانگین داده‌ها را تغییر دهد اما میانه تقریباً ثابت بماند؟ (۰.۲۵ نمره)
- الف) حذف یک داده‌ی گم‌شده
ب) اضافه‌شدن یک مقدار بسیار بزرگ به داده‌ها
ج) مرتب‌کردن داده‌ها
د) تغییر نام دسته‌های یک متغیر اسمی
۳. در یک آزمون فرض، مقدار $p\text{-value} = 0.12$ و سطح معناداری $\alpha = 0.05$ است. کدام گزینه صحیح است؟ (۰.۲۵ نمره)
- الف) فرض صفر با احتمال ۸۸ درصد درست است.
ب) فرض صفر باید پذیرفته شود.
ج) در سطح معنی‌داری ۵ درصد، شواهد کافی برای رد فرض
د) نتیجه آزمون از نظر آماری و علمی بی‌اعتبار است.
صفر وجود ندارد.
۴. اگر هدف علاوه بر بررسی رابطه، تشخیص الگوهای غیرخطی و داده‌های پرت^۲ نیز باشد، کدام نمودار مناسب‌تر است؟ (۰.۲۵ نمره)
- الف) Histogram ب) Pie Chart ج) Scatter Plot د) Bar Chart
۵. میانگین درآمد کارکنان یک شرکت ۸۰ میلیون تومان است. کدام نتیجه‌گیری بدون داشتن اطلاعات بیشتر قابل دفاع نیست؟ (۰.۲۵ نمره)
- الف) ممکن است توزیع درآمد چوله^۳ باشد.
ب) ممکن است چند درآمد بسیار بالا میانگین را افزایش داده باشند.
ج) اکثر کارکنان الزاماً درآمدی نزدیک به ۸۰ میلیون تومان دارند.
د) برای توصیف بهتر، میانه و چارک‌ها^۴ نیز باید بررسی شوند.

¹ Missing value

² Outlier

³ Skewness

⁴ Quartile

۶. کدام پرسش مستقیماً یک پرسش علی است، نه صرفاً پیش‌بینی یا بررسی ارتباط؟ (۰.۲۵ نمره)

الف) آیا می‌توان براساس ویژگی‌های ایمیل، هرنامه‌بودن آن را پیش‌بینی کرد؟

ب) آیا یک برنامه آموزش شغلی باعث افزایش اشتغال می‌شود؟

ج) قد والدین با قد فرزندان چه رابطه‌ای دارد؟

د) چگونه می‌توان یک مقاله را خلاصه کرد؟

۷. چرا در مینی‌دسته یا SGD ممکن است زیان در یک به‌روزرسانی خاص افزایش یابد؟ (۰.۲۵ نمره)

الف) چون این روش‌ها هیچ گرادیانی محاسبه نمی‌کنند.

ب) چون نرخ یادگیری همیشه صفر است.

ج) چون تابع زیان در هر گام عوض می‌شود.

د) چون گرادیان براساس زیرمجموعه‌ای از داده تخمین زده شده و نویزی است.

۸. مدلی به شکل $y = \beta_0 + \beta_1 x + \beta_2 x^2$ پیش‌بینی می‌کند. چرا هنوز آن را مدل خطی می‌نامیم؟ (۰.۲۵ نمره)

الف) زیرا x^2 همیشه یک خط راست است.

ب) زیرا مدل نسبت به پارامترهای β_0 ، β_1 و β_2 خطی است.

ج) زیرا دقیقاً دو ویژگی دارد.

د) زیرا پیش‌بینی آن نمی‌تواند منحنی باشد.

۹. مدل استخدام جنسیت را دریافت نمی‌کند، اما از متغیرهای بسیار همبسته استفاده کرده و تبعیض را بازتولید می‌کند.

مسئله اصلی چیست؟ (۰.۲۵ نمره)

الف) متغیرهای جانشین می‌توانند حتی پس از حذف ویژگی حساس، رفتار ناعادلانه را حفظ کنند.

ب) مدل تعداد کلاس کمی دارد.

ج) مدل از یادگیری نظارت‌شده استفاده می‌کند.

د) مجموعه‌داده الزاماً خیلی کوچک است

بخش دوم: سوالات صحیح/غلط (۱.۷۵ نمره) (با توضیح مختصر)

۱. داده‌ی گم‌شده و داده‌ی پرت دو نام متفاوت برای یک مفهوم یکسان هستند. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۲. کوچک‌تر شدن مقدار p -value الزاماً به معنای بزرگ‌تر بودن اندازه اثر یا مهم‌تر بودن عملی نتیجه آزمون است. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۳. یک نمودار می‌تواند با وجود استفاده از داده‌های صحیح، به دلیل انتخاب نامناسب مقیاس، محور یا شیوه نمایش، برداشت گمراه‌کننده ایجاد نماید. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۴. افزایش حجم نمونه معمولاً خطای تصادفی را کاهش می‌دهد و همواره منجر به افزایش صحت نتایج تحلیل‌ها می‌گردد. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۵. استفاده بی‌قید و شرط از رنگ در نمودارها منجر به درک بهتر تحلیل آماری می‌گردد. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۶. دو مجموعه داده می‌توانند MSE یکسانی داشته باشند، اما ساختار رابطه و الگوی باقیمانده آن‌ها کاملاً متفاوت باشد. (۰.۲۵ نمره)
☐ غلط ☐ صحیح
۷. تابع فعال‌ساز غیرخطی فقط برای محدود کردن خروجی نهایی استفاده می‌شود و در لایه‌های پنهان نقشی در قدرت بیان ندارد. (۰.۲۵ نمره)
☐ غلط ☐ صحیح

بخش سوم: سوالات کوتاه پاسخ (۲ نمره)

۱. اگر دو رویداد A و B مستقل باشند، احتمال وقوع هم‌زمان آن‌ها چگونه محاسبه می‌شود؟ (۰.۲۵ نمره)
۲. نمونه‌گیری برای بررسی کیفیت محصولات یک خط تولید بدون وقفه، چطور بهتر است انجام شود؟ (۰.۲۵ نمره)
۳. در داده‌های دارای چولگی توزیع و وجود چند مقدار بسیار بزرگ، کدام نمودار یا ترکیب نمودارها برای شناسایی داده پرت مناسب‌تر است؟ چرا؟ (۰.۵ نمره)
۴. چیدمان اجزای یک داشبورد (جریان داشبورد^۵) بر چه اساسی است؟ (۰.۵ نمره)
۵. چرا از pooling در CNN استفاده می‌شود در حالی که پارامتری به مدل اضافه نمی‌کند؟ (۰.۵ نمره)

^۵ Dashboard flow

بخش چهارم: سوالات تشریحی (۱۰ نمره)

۱- تحلیل داده: جدول زیر بخشی از اطلاعات مشتریان یک فروشگاه اینترنتی را نشان می‌دهد. چهار مورد از مشکلات موجود در داده را شناسایی نموده و برای هر یک مناسب‌ترین روش پیش‌پردازش را پیشنهاد دهید. (۲ نمره)

شماره مشتری	سن	جنسیت	شهر	هزینه فاکتور
۱۰۰۱	۲۴	مرد	تهران	1,250,000
۱۰۰۲	۲۵	زن	مشهد	980,000
۱۰۰۳	۲۴	مرد	Tehran	-150,000
۱۰۰۴	NaN	زن	شیراز	870,000
۱۰۰۲	۲۵	زن	مشهد	980,000
۱۰۰۵	۱۶۵	مرد	تهران	1,150,000
۱۰۰۶	۳۰	زن	تهران	NaN
۱۰۰۷	۲۸	زن	تهران	920000
۱۰۰۸	۲۸	زن	تهران	920,000

۲- مغالطه آماری: برای هر یک از گزاره‌های زیر مشخص نمایید آیا مغالطه آماری (به معنای استفاده نادرست یا گمراه‌کننده از داده‌های آماری یا تحلیل اشتباه) وجود دارد یا خیر. پاسخ خود را به طور کامل شرح دهید. (۲ نمره)

- شهرداری تهران اعلام کرده است که پس از افتتاح یک خط جدید مترو، میانگین زمان سفرهای درون‌شهری ۱۰٪ کاهش یافته است. لذا افتتاح این خط مترو علت اصلی کاهش زمان سفر شهروندان بوده و پروژه کاملاً موفق ارزیابی می‌شود.
- در یک نظرسنجی اینترنتی که در صفحه اینستاگرام یک خبرگزاری انجام شده است، ۹۰٪ شرکت‌کنندگان اعلام نموده‌اند که آموزش مجازی را به آموزش حضوری ترجیح می‌دهند. بنابراین اکثر دانشجویان کشور نیز آموزش مجازی را ترجیح می‌دهند.
- ۴۵٪ افراد یک شهر زن هستند و ۳۰٪ افراد این شهر به موسیقی کلاسیک علاقه دارند. لذا ۱۳.۵٪ جمعیت شهر را زنان علاقه‌مند به موسیقی کلاسیک تشکیل می‌دهند.
- برای بررسی رضایت دانشجویان دانشگاه، ابتدا دانشجویان بر اساس دانشکده طبقه‌بندی شدند. سپس از هر دانشکده متناسب با تعداد دانشجویان آن، نمونه‌ای به صورت تصادفی انتخاب شد و نتایج به کل دانشگاه تعمیم داده شد.

۳- طراحی و ارزیابی سامانه retrieval augmented generation (۲ نمره)

یک سامانه RAG برای پاسخ‌گویی به اسناد دانشگاهی خصوصی طراحی کنید. مراحل آماده‌سازی اسناد، قطعه‌بندی، بازیابی، ساخت پرامپت، تولید پاسخ و استناد را توضیح دهید. سپس یک چارچوب ارزیابی ارائه کنید که خطای بازیابی را از خطای تولید جدا کند.

۴- Attention، بافت و استدلال (۲ نمره)

بازنمایی وابسته به بافت چیست؟ توضیح دهید Attention چگونه می‌سازد و چرا این سازوکار برای مدل‌سازی زبان مهم است.

۵- پیش‌بینی قیمت خانه (۲ نمره)

اگر بخواهید از روی داده‌های سایت دیوار، مدلی جهت پیش‌بینی قیمت خانه بسازید، چه می‌کنید؟